

Entwicklung der EyeAI Rel2abs Modelle

Von relativen Tiefenwerten zur metrischen Tiefe mit visueller und geometrischer Unterstützung

Entwicklungsdokumentation | Stand 20 September 2026 | Algorithmic Alliance

ZIEL DER DOKUMENTATION

Diese Dokumentation fasst die Entwicklung von Rel2abs als lokaler Modellpipeline zusammen. Im Mittelpunkt stehen die Modellentscheidungen, die wichtigsten Datensätze, die messbaren Verbesserungen und die Gründe, aus denen Forschungsvarianten nicht in die sichere Produktlinie übernommen wurden.

Ergebnis: Das aktuelle Forschungsergebnis ist ein kalibriertes Hybrid-Modell. Es verbindet die visuelle Baseline mit dem F1-Größenanker und lernt, wann F1 verlässlich ist. YOLO liefert Objekt- und Kontextmerkmale, die vorhandene Segmentierung ergänzt Szeneninformationen, und die kalibrierte Kamerahöhe wird mitverwendet. Auf sauber getrennten Daten ohne identische Aufnahmen in Training und Test war das Modell besonders im Fernbereich deutlich besser als die Vergleichsmodelle. Im Real-World-Test mit sichtbaren Objekten und korrekt eingestellter Kamerahöhe zeigte es ebenfalls sehr gute Ergebnisse. Numerische Rohwerte für diesen Test liegen weiterhin nicht vor.

Die Entwicklung in Kurzform

1. Candidate-3 und Candidate-4 waren frühe Versuche, die Tiefe in mehrere Abstandsbereiche aufzuteilen. Hilfsinformationen aus der Ground Truth (Oracle-Informationen) machten diese Varianten zwar stark, aber nicht für den späteren Einsatz geeignet.
2. Z1 und Baseline-2P wurden als feste visuelle Vergleichsbasis festgelegt. Sie arbeiten ohne die späteren Objektgrößen- und Zusatzinformationen.
3. S2 war ein kleines Zusatznetz auf zusammengefassten MiDaS-Merkmalen. Es brachte ein Signal, aber keinen stabilen Grund für einen Austausch der Baseline.
4. Spline-Modelle veränderten die Umrechnung der relativen Tiefe in eine metrische Tiefe. Spline-8 war dabei der beste rein visuelle Forschungszweig, aber nicht über alle Trainingsläufe gleich zuverlässig.
5. Der F1-Größenanker war auf KITTI stark, konnte im Nahbereich von Waymo aber deutlich scheitern. Deshalb sollte F1 nie allein entscheiden.
6. B3 verband Visual- und Größenpfad zunächst mit festen Regeln. Das aktuelle Hybrid-Gate lernt diese Entscheidung aus Tiefe, YOLO, Segmentierung und Kamerahöhe.

Rel2abs Modellpipeline

Vom relativen MiDaS-Signal zur metrischen Tiefe



Das Gate verarbeitet YOLO- und Segmentierungskontext sowie die kalibrierte Kamerahöhe.

Es interpoliert nur zwischen Visual- und F1-Tiefe. Bei geringer F1-Verlässlichkeit bleibt der visuelle Pfad dominant.

Abbildung 2: Vereinfachte Rel2abs-Pipeline. Das neuronale Gate nutzt die verfügbaren Kontextmerkmale, gibt aber weiterhin nur eine begrenzte Fusion aus Visual- und F1-Tiefe aus.

Die wichtigsten Modellnamen einfach erklärt

Die Namen bezeichnen Entwicklungsstufen und Versuchslinien. Candidate-1 bis Candidate-X waren keine feste Modellfamilie mit immer gleicher Architektur. Die Bezeichnung Candidate markierte jeweils einen frühen Versuch. Für die Entwicklung von Rel2abs sind vor allem Candidate-3 und Candidate-4 sowie die späteren Linien Z1, S2, Spline, F1, B3 und das aktuelle Hybrid-Gate wichtig.

Name	Was steckt dahinter?	Rolle im Projekt
Candidate-3	Frühes Binreg-Modell. Es teilte die Tiefe in mehrere Bereiche ein und schätzte darin Werte.	Wichtiger Lernschritt, aber nicht für den Einsatz übernommen.
Candidate-4	Frühes Multiband-Modell. Mehrere Tiefenbereiche wurden getrennt behandelt.	Zeigte Möglichkeiten und Grenzen mehrerer Teilmodelle.
Z1	Ältere feste Referenz aus DIODE und NYU. Sie dient als Vergleichslinie für die späteren Varianten.	Historische visuelle Referenz.
Baseline-2P	Kleine visuelle Kalibrierung. Sie nutzt das MiDaS-Signal und globale Bildmerkmale und bestimmt im Kern Maßstab und Verschiebung.	Aktuelle visuelle Vergleichsbasis und sicherer Fallback.
S2	Kleines Zusatznetz. Es nutzt zusammengefasste MiDaS-Werte und ein grobes 4x4-Bild der relativen Tiefe.	Diagnosemodell mit brauchbarem, aber nicht stabilem Zusatzsignal.
S3a und S3b	Versuche, fehlende MiDaS-Merkmale nur aus dem RGB-Bild nachzubilden.	Zero-Shot-Forschung, aber kein robuster Ersatz für S2 oder die Baseline.
Spline-8	Eine monotone Kurve übersetzt relative MiDaS-Werte in metrische Werte. Sie nutzt keine Objekte.	Beste rein visueller Forschungszweig, aber abhängig vom Trainingslauf.
F1	Analytischer Größenanker aus der Lochkamera-Idee. Objektgröße und Boxgröße ergeben eine zusätzliche Tiefenschätzung.	Starker Hinweis, aber allein im Nahbereich nicht sicher genug.
B3	Regelbasierte Mischung aus visueller Tiefe und F1. Bei widersprüchlichen Signalen wird auf die Baseline zurückgefallen.	Wichtige Zwischenstufe und nachvollziehbarer Fallback.
Aktuelles Hybrid-Gate	Kleines neuronales Entscheidungsnetz. Es lernt ein Vertrauensgewicht für F1 und nutzt YOLO, Segmentierung und Kamerahöhe als Kontext.	Aktuelles bestes Forschungsergebnis.

Tabelle 1: Die Modellnamen beschreiben unterschiedliche Ideen. Sie sind nicht alle direkte Vorgänger desselben Netzes.

Begriffe, die in der Dokumentation vorkommen

- Oracle-Information bedeutet, dass ein Modell für eine Analyse bereits die richtige Tiefe oder einen Fehler aus der Ground Truth kennt. Das ist nützlich als theoretische Obergrenze, steht im späteren Einsatz aber nicht zur Verfügung.
- Pseudo-GT bedeutet eine geschätzte Referenz. Im COCO-Test stammt sie aus mehreren Lehrmodellen und ist deshalb keine direkt gemessene Tiefe.
- Getrennte Aufnahmen bedeutet, dass sehr ähnliche Bilder derselben Szene nicht gleichzeitig zum Lernen und zum Testen verwendet werden. So wird verhindert, dass das Modell eine Szene nur wiedererkennt.
- Ein Seed ist nur der zufällige Startwert eines Trainingslaufs. Unterschiedliche Seeds zeigen, ob ein Ergebnis stabil oder eher zufällig ist.

1. Ausgangspunkt und Anforderungen

MiDaS liefert eine relative Tiefe. Es erkennt also, welche Bildbereiche näher oder weiter entfernt sind, kennt aber nicht automatisch die Entfernung in Metern. Rel2abs soll daraus eine metrische Tiefe in Metern erzeugen, die in EyeAI klein, exportierbar und kontrollierbar eingesetzt werden kann. Die zentrale Frage war deshalb nicht nur, welches Modell im Mittel den kleinsten Fehler erreicht. Entscheidend war, ob die Verbesserung ohne Datenleck, ohne versteckte Testanpassung und ohne unbestätigte Zusatzannahmen stabil bleibt.

Die Entwicklung wurde deshalb in getrennte Ebenen aufgeteilt. Pixelmetriken auf DIODE werden nicht mit Objektmetriken auf KITTI oder Waymo vermischt. COCO dient als pseudo-GT-Stresstest (Vergleich mit einer geschätzten Referenz, nicht mit direkt gemessener Tiefe). Waymo liefert den wichtigsten externen Objektvergleich. Messungen mit der in EyeAI verwendeten YOLO-Erkennung und offizielle Boxen bleiben getrennte Auswertungen.

Produktanforderungen

- Die visuelle Referenz soll ohne Oracle-Information (vorab bekannte Ground Truth) und ohne eine spezielle Anpassung an Waymo auskommen.
- Die Modellgröße soll klein genug für einen mobilen Export bleiben.
- Verbesserungen müssen über mehrere Datensätze und Distanzbereiche geprüft werden.
- Ein Größenprior darf bei widersprüchlichen Signalen nicht unkontrolliert dominieren.
- Unbekannte Daten, fehlende numerische Messwerte und pseudo-GT (geschätzte Referenz) werden ausdrücklich markiert.

Datensätze und ihre Rolle

Datensatz	Rolle	Ground Truth	Wichtige Einschränkung
DIODE	festgelegter Pixelvergleich	gemessene Tiefenwerte	Nicht direkt mit Objektmetriken gleichsetzen
KITTI	Objektgrößen und Höhenvergleich	LiDAR-basierte Objektwerte	EyeAI-Nahbereich dünn besetzt
Waymo	externer Objektvergleich	LiDAR-basierte Tiefenmessung	Im Nahbereich wenige Beispiele
COCO	externer Stresstest	Schätzreferenz aus Lehrmodellen	Keine direkt gemessene Tiefe
Real World	qualitative EyeAI Prüfung	nicht dokumentiert	Numerische Rohwerte fehlen

Tabelle 2: Rollen und Grenzen der wichtigsten Auswertungsspuren.

2. Von frühen Kandidaten zu Z1

Candidate-3 und Candidate-4 bildeten die frühe Linie mit mehreren Tiefenbereichen. In V1 wurden Datensatzbalance, Geometrie, Trainingsziel und Hilfsinformationen aus der Ground Truth verglichen. Die Oracle-Varianten konnten lokal stark wirken, kannten aber Informationen, die im späteren Produktlauf nicht verfügbar sind. Sie wurden deshalb nicht übernommen.

Z1 wurde anschließend als Referenz aus DIODE und NYU festgelegt. Baseline-2P bezeichnet die spätere, kleine visuelle Kalibrierung. Sie nutzt das MiDaS-Signal und globale Bildmerkmale, um den Maßstab der relativen Tiefe zu bestimmen. Beide stehen für den visuellen Fallback ohne pseudo-GT, Objektgrößenannahme oder spezielle Waymo-Anpassung.

Referenz	Parameter	DIODE AbsRel	Waymo AbsRel	Rolle
Z1	21.351	0,591	0,756	eingefrorene Referenz
Baseline-2P	nicht neu geschätzt	0,665	0,789	V6 Produktionsfall-back

Tabelle 3: Die sichere visuelle Linie. Niedrigere Werte sind besser. Die Auswertungen bleiben getrennt.




Abbildung 3: Entwicklung der DIODE AbsRel im festgelegten V6-Vergleich. Spline-8 verbessert die Baseline, erreicht aber nicht die Z1-Referenz.

3. Kleine Zusatznetze und Spline-Modelle

S2 und selektive Kalibrierung

S2 war ein kleines Zusatznetz auf dem MiDaS-Ergebnis. Es bekam zusammengefasste Werte aus dem Bild sowie ein grobes 4x4-Muster der relativen Tiefe. Sein Ziel war, den Maßstab der MiDaS-Tiefe besser an reale Meterwerte anzupassen. Die drei Trainingsläufe mit unterschiedlichen zufälligen Startwerten lagen beim Fehler zwischen 0,60834 und 0,61348. Das Signal war brauchbar, aber nicht in allen Datenbereichen gleich stabil.

Die selektive Kalibrierung sollte nur dann auf S2 zurückgreifen, wenn dieses Zusatznetz wahrscheinlich hilft. Dafür wurde ein weiteres kleines Entscheidungsmodell getestet. Der Vorteil gegenüber der ständigen Nutzung von S2 war jedoch nicht eindeutig genug für eine Ablösung der Baseline.

S3a und S3b versuchten, fehlende MiDaS-Merkmale allein aus dem RGB-Bild nachzubilden. Das war ein Versuch für Situationen, in denen nicht alle Eingangsdaten vorhanden sind. Beide Varianten blieben hinter S2 zurück und wurden nicht integriert.

Spline-8 als bester rein visueller Forschungszweig

Spline-Modelle ersetzen die einfache Umrechnung der MiDaS-Werte durch eine kontrollierte Kurve. Spline-8 verwendete acht Abschnitte und durfte nur monoton verlaufen. Dadurch wurde ein steigender oder fallender Zusammenhang nicht unkontrolliert umgedreht. Auf dem festgelegten DIODE-Vergleich sank die AbsRel von 0,5731 für Baseline-2P auf 0,5305 für Spline-8. Im späteren Waymo-Vergleich lag Spline-8 mit Startwert 7 bei 0,6660 gegenüber 0,6655 für Baseline-2P.

Der Vorteil war jedoch nicht bei jedem Trainingslauf gleich. Deshalb ist Spline-8 ein wertvoller Forschungszweig, aber keine sichere alleinige Produktentscheidung.

DIODE Gold Pixel	AbsRel	MAE m	RMSE m	MedAE m	p95 m	delta1
Z1	0,591	8,493	17,178	1,814	27,524	0,184
Baseline-2P	0,665	9,325	17,976	2,467	29,825	0,106
Spline-8, Startwert 7	0,612	8,675	17,402	2,072	28,123	0,192

Tabelle 4: Ausgewählte DIODE-Metriken. AbsRel, MAE, RMSE, MedAE und p95 sind Fehlermaße. delta1 misst den Anteil innerhalb eines Faktors von 1,25.

4. Objektgrößen und Kamerahöhe

F1 als Größenanker: die Lochkamera-Idee

F1 ist in diesem Projekt kein F1-Wert aus der Klassifikation. F1 ist der Name für den ersten Größenanker. Die Idee kommt aus der Lochkamera-Geometrie. Wenn die reale Höhe H eines Objekts, die Brennweite f der Kamera und seine Höhe h in Pixeln bekannt sind, gilt vereinfacht: Entfernung Z ist ungefähr f mal H geteilt durch h . Ein großes Objektbild bedeutet also meist, dass das Objekt näher ist.

Genau hier treffen sich Rel2abs und die bereits vorhandene EyeAI-Pipeline. YOLO erkennt die Objektklasse und liefert die Bounding-Box. Aus der Höhe und Breite dieser Box kann F1 eine zusätzliche Tiefenschätzung ableiten. Die Segmentierung hilft dabei, den sichtbaren Objekt- und Szenenbereich besser zu beschreiben. Dafür musste kein völlig neuer Wahrnehmungszweig erfunden werden. EyeAI nutzt diese Informationen bereits.

In der Praxis kennt das Modell die exakte reale Objektgröße nicht immer. Für eine Person oder ein Fahrzeug wird deshalb mit typischen Größen und mit der erkannten Klasse gearbeitet. Eine falsche Klasse oder eine ungenaue Box kann die Tiefenschätzung stark verschieben. F1 ist deshalb ein wertvoller Hinweis, aber keine sichere alleinige Antwort.

V5A untersuchte, ob dieses geometrische Signal stabil genug ist. Auf KITTI erreichte die Kombination aus Baseline und F1 bei korrekter Klasse 0,1994 AbsRel. Mit einer falschen Klasse lag der Kontrollwert bei 0,4626. Das war ein starkes lokales Signal, aber noch kein Beleg für Sicherheit auf anderen Datensätzen.

Waymo zeigte die Grenze deutlich. F1 erreichte insgesamt 0,3062 AbsRel, verschlechterte den EyeAI-Nahbereich aber von 0,2499 auf 1,7226. Deshalb darf F1 nicht allein entscheiden. Im aktuellen Hybrid-Modell wird genau diese Unsicherheit durch das Vertrauensnetz berücksichtigt.




Abbildung 4: Waymo AbsRel. F1 ist im Gesamtbild stark, darf wegen des Nahbereichs aber nicht allein entscheiden.

Das aktuelle kontextbasierte Hybrid-Modell

Das neue Endergebnis verbindet zwei bereits verständliche Schätzungen. Die visuelle Baseline liefert eine Tiefe aus dem MiDaS-Signal. F1 liefert aus der erkannten Objektgröße einen metrischen Größenanker. Beide Werte werden im Lograum zusammengeführt. Das Modell erzeugt also keine völlig freie Tiefe, sondern bleibt zwischen dem visuellen Wert und dem F1-Wert begrenzt.

Die eigentliche Entscheidung übernimmt ein kleines neuronales Gate. Es berechnet ein Vertrauensgewicht für F1. Dazu sieht es die visuelle Tiefe, die F1-Tiefe, die absolute und signierte Abweichung zwischen beiden Werten sowie Kontextmerkmale. Wenn F1 wegen einer falschen Klasse, einer ungünstigen Box oder einer unpassenden Objektgröße wenig vertrauenswürdig wirkt, verschiebt das Gate die Ausgabe zurück in Richtung Baseline. Wenn die Objekt- und Kamerainformationen konsistent sind, darf F1 stärker einfließen.

YOLO ist damit eine wichtige Abhängigkeit des Hybrid-Modells. Die Objekterkennung liefert Boxen, Klassen, Konfidenzen, Objektanzahl und Größenmerkmale. Die vorhandene semantische Segmentierung ergänzt globale und boxnahe Informationen über die sichtbare Szene. Sie ist kein neu trainiertes Segmentierungsnetz innerhalb des Rel2abs-Gates. Fehlen Segmentierungsmerkmale, wird diese Verfügbarkeit im Kontext berücksichtigt.

Die Kamerahöhe ist ein kalibrierter Eingabewert. Das Modell kennt damit die Montagehöhe der Kamera als Kontext und lernt, wie stark diese Information die F1-Schätzung stützen darf. Sie ersetzt keine Objekterkennung. Eine falsche oder nicht zur Aufnahme passende Höhe kann den Größenanker systematisch verschieben. Die Qualität des Hybrid-Modells hängt deshalb von gültigen YOLO-Ergebnissen, verfügbaren Segmentierungsmerkmalen und einer korrekt eingestellten Kamerahöhe ab.

- Visual und F1 bleiben die beiden begrenzten Tiefenanker.
- Das Gate bewertet die Verlässlichkeit von F1 und gibt nur ein Mischgewicht aus.

- YOLO liefert Objekt-, Box- und Konfidenzmerkmale für den Kontext.
- Segmentierung liefert globale und boxlokale Szenenmerkmale.
- Die Kamerahöhe wirkt als kalibrierte Zusatzinformation und muss zur Aufnahme passen.

Kamera-Höhe als Modellkontext

V6 testete Forschungssweeps zwischen 1,60 m und 2,00 m. Der Wert 1,70 m war im dokumentierten Dev-Split am besten. Dieser Wert ist keine universelle Kalibrierung. Für den Real-World-Test war entscheidend, dass die verwendete Kamerahöhe korrekt eingestellt war und sich zugleich Objekte im Sichtfeld befanden.




Abbildung 5: Fehlerverteilung der Baseline nach Waymo Distanzbereich. Die kurzen Bänder haben geringe Stichproben und müssen vorsichtig interpretiert werden.

5. V6 Fusion und finale Auswahl

V6 hielt die visuelle Baseline und den F1-Größenanker zunächst fest und verglich verschiedene Mischregeln. Getestet wurde, wie stark F1 einfließen darf, wann wegen widersprüchlicher Werte auf die Baseline zurückgefallen wird und ob ein kleines neuronales Entscheidungsnetz diese Wahl besser treffen kann. B3 war dabei die stabile regelbasierte Zwischenstufe. Das aktuelle Ergebnis ist die nächste Ausbaustufe: ein Object-Feature-Gate, das seine F1-Vertrauensgewichtung aus den verfügbaren Bild- und Kontextmerkmalen lernt.

B3 Disagreement-Fallback

B3 vergleicht die Größen- und die visuelle Schätzung. Wenn beide stark auseinanderliegen oder F1 wenig zuverlässig wirkt, bleibt die Pipeline bei der visuellen Baseline. Wenn die Werte zusammenpassen, wird F1 begrenzt zugemischt. B3 ist damit eine nachvollziehbare Regel und kein frei arbeitendes Regressionsmodell.

- Der Gesamtfehler darf gegenüber der Baseline nicht steigen
- Der Nahbereich von 0,5 bis 5 m darf nicht schlechter werden
- Der Bereich von 5 bis 10 m darf nicht schlechter werden
- Die Verbesserung muss auch bei den echten YOLO-Ergebnissen sichtbar bleiben
- Das Modell soll in mindestens 80 Prozent der Fälle eine Ausgabe liefern
- Höchstens 5 Prozent der Fälle dürfen verworfen werden

B3 bestand diese frühere Entscheidungslogik und bleibt deshalb als nachvollziehbarer Fallback wichtig. Für die aktuelle Modellforschung ist jedoch das lernende Object-Feature-Gate das stärkere Ergebnis. Es nutzt dieselbe kontrollierte Fusion, ersetzt die festen B3-Regeln aber durch ein trainiertes Vertrauensmodell. Das Gate wurde auf einer Aufteilung mit getrennten Trainings-, Entwicklungs- und Prüfdaten untersucht. Sehr ähnliche Aufnahmen derselben Szene wurden dabei nicht auf beide Seiten verteilt.

Waymo Vergleich	AbsRel	MAE m	RMSE m	MedAE m	p95 m	delta1	Entscheidung
Z1	0,756	34,346	38,409	33,141	61,628	0,011	Referenz
Baseline-2P	0,789	35,323	39,183	34,186	62,722	0,003	sicherer Fallback
Spline-8, Startwert 7	0,666	31,063	35,522	29,903	58,941	0,040	Forschung
F1 Größe-anker	0,306	12,309	21,583	6,620	43,097	0,590	Nahbereich nicht sicher
B3 Hybrid	0,783	35,232	39,158	34,186	62,722	0,007	Hybridkandidat

Tabelle 5: Historische V6-Auswahl vor dem Object-Feature-Gate. B3 war der regelbasierte Hybridkandidat. Die Tabelle erklärt, warum der neue Gate-Ansatz auf einem sicheren Fallback aufbaut.

Messbarer Vorteil des aktuellen Hybrid-Gates

Die neue Auswertung umfasst 325 Varianten des Vertrauens-Gates und einen Waymo-Prüfdatensatz mit 1.138 Objekten. Die beste Gesamtvariante kombinierte Tiefe, Kamerahöhe, Boxbreite, Form und Position, F1-Anker, Objekterkennung und Segmentierung. Auf dem gesamten Waymo-Prüfdatensatz sank die AbsRel von 0,7928 für Baseline-2P auf 0,1694. F1 allein lag bei 0,2932. Das zeigt, dass die Stärke nicht aus F1 allein kommt, sondern aus der gelernten Entscheidung, wann F1 vertrauenswürdig ist.

Besonders deutlich ist der Fernbereich. Für Objekte ab 15 m sank die AbsRel von 0,8111 bei der Baseline auf 0,1674 beim Object-Gate. Gleichzeitig fiel der MAE von 37,956 m auf 7,658 m und der RMSE von 41,125 m auf 10,227 m. Auch in den mittleren Bereichen war das Gate klar besser. Im ver-

fügbaren Nahbereich von 2 bis 5 m lag es mit 0,2871 AbsRel unter der Baseline mit 0,3123. Dieser Nahbereich enthielt allerdings nur drei Objekte und ist deshalb vorsichtig zu bewerten.


Auch im COCO-Stresstest zeigte sich derselbe Trend. Über alle Distanzen sank die AbsRel von 0,7180 für die Baseline auf 0,6161 beim Object-Gate. Ab 15 m sank sie von 0,8894 auf 0,6542. COCO basiert auf pseudo-GT und ist deshalb ein Belastungstest, aber keine alleinige Zertifizierung.

Waymo-Bereich	n	Baseline AbsRel	F1 AbsRel	Gate AbsRel	Gate MAE m	Gate RMSE m
ALL	1.138	0,7928	0,2932	0,1694	7,335	9,865
2 bis 5 m	3	0,3123	0,8556	0,2871	1,207	1,675
5 bis 10 m	18	0,4315	0,4746	0,2054	1,889	3,010
10 bis 15 m	53	0,5767	0,2640	0,1532	2,000	2,502
>= 15 m	1.064	0,8111	0,2900	0,1674	7,658	10,227

Tabelle 6: Aktuelles Vertrauens-Gate auf dem Waymo-Prüfdatensatz. Die beste Merkmalskombination darf je Distanzbereich variieren. Die Nahbereichszahl ist wegen n = 3 nur ein vorsichtiger Hinweis.

Aktuelles Hybrid-Gate auf den Waymo-Prüfdaten

AbsRel, kleinere Werte sind besser. Das Gate darf nur zwischen Visual- und F1-Tiefe interpolieren.



Der größte Gewinn liegt im Fernbereich. Im verfügbaren Nahbereich war das Gate ebenfalls besser als die Baseline, dort ist die Stichprobe jedoch klein.

Abbildung 6: Das aktuelle Hybrid-Gate verbessert den Gesamtfehler und besonders den Fernbereich deutlich. F1 allein ist stark, aber nicht ausreichend. Das Gate lernt, wann F1 genutzt werden darf.

6. Wichtigste Metriken und ihre Bedeutung

Für kontinuierliche Tiefe werden mehrere Fehlermaße gemeinsam betrachtet. Ein einzelner Mittelwert kann durch wenige große Ausreißer oder durch eine ungleichmäßige Distanzverteilung verzerrt werden. Deshalb werden zentrale Modelle über AbsRel, absolute Fehler in Metern und den Delta1-Anteil beschrieben.

Metrik	Bedeutung	Richtung
AbsRel	mittlerer relativer Absolutfehler	kleiner ist besser
MAE	mittlerer absoluter Fehler in Metern	kleiner ist besser
RMSE	bestraft große Fehler stärker	kleiner ist besser

Metrik	Bedeutung	Richtung
MedAE	Median des absoluten Fehlers in Metern	kleiner ist besser
p95	95. Perzentil des absoluten Fehlers	kleiner ist besser
delta1	Anteil mit maximalem Verhältnis unter 1,25	größer ist besser

Tabelle 7: Metrikdefinitionen für die Rel2abs-Auswertung.

7. Ergebnis, Grenzen und nächster Schritt

Was als Ergebnis gilt

- Baseline-2P bleibt der sichere visuelle Fallback, wenn Kontextmerkmale fehlen oder ungültig sind.
- Spline-8 mit Startwert 7 ist der beste rein visuelle Forschungszweig im dokumentierten externen Vergleich, aber nicht über alle Trainingsläufe gleich stabil.
- F1 liefert ein starkes Objektgrößensignal, darf aber wegen seiner Fehler im Nahbereich nicht allein ausgeben.
- Das aktuelle Endergebnis ist das kalibrierte Object-Feature-Gate, das Visual und F1 mit YOLO-, Segmentierungs- und Höhenkontext verbindet.
- Auf den ausgewerteten Waymo-Prüfdaten war der Vorteil im Fernbereich besonders groß und auch in den mittleren Bereichen klar sichtbar.
- Im Real-World-Test mit Objekten im Sichtfeld und korrekt eingestellter Kamerahöhe zeigte der Hybrid sehr gute qualitative Ergebnisse.

Schlussfolgerung

Rel2abs hat sich von einer Folge einzelner Regressionsideen zu einer kontrollierten Modellpolitik entwickelt. Die stärkste Verbesserung war nicht nur ein niedrigerer Fehler. Entscheidend war die Trennung von visueller Referenz, Objektprior, Fusion und Sicherheitsgates. Dadurch bleibt nachvollziehbar, welche Varianten wirklich robust sind, welche nur diagnostisch helfen und an welcher Stelle neue Messungen nötig sind.